



Análisis exploratorio de datos (EDA)

Contentment

Happiness Index

Gratitude

En este documento se hará un análisis sobre los datos para el estudio del nivel de felicidad. Se buscarán, o intentarán explicar, las posibles incoherencias o resultados remarcables en un análisis estadístico de la fuente de los datos.

Variables numéricas

Se hará primero un estudio de variables con valores numéricos de nuestros datos originales.

Estadísticas descriptivas

A continuación, se muestran los datos estadísticos más representativos para nuestro conjunto de datos.


	edad	dias_alta_contaminacion	horasTrabajadas_mes	salario_anual	percepcion_seguridad	nivel_felicidad
count	20.000,00	20.000,00	20.000,00	20.000,00	20.000,00	20.000,00
mean	47,29	7,82	140,52	24.232,47	6,96	7,11
std	20,85	7,49	53,54	9.546,81	0,81	1,13
min	10,00	0,00	0,00	0,00	2,09	2,40
25%	31,00	3,24	118,07	20.022,76	6,41	6,10
50%	47,00	5,67	148,16	25.391,57	6,96	7,50
75%	62,00	9,35	174,77	30.358,33	7,51	8,00
max	110,00	41,03	306,80	52.902,35	9,75	9,20

Vemos que la desviación estándar es suficientemente elevada en casi todos los casos como para suponer que la distribución está muy repartida entre todo el rango de valores.

Distribución de variables numéricas


En el siguiente gráfico se podrán ver las distribuciones de los valores que toman nuestras variables en nuestro rango de resultados.





En estas distribuciones hay unas apreciaciones que explicaremos a continuación, viendo los resultados de forma individual.


Edad



La distribución de la edad se corresponde con una población envejecida, con un pico alrededor de los 50 años. La media de la edad es de 47 años, con una desviación estándar de 20 años. Esto indica que la mayoría de los pacientes tienen entre 37 y 67 años.


Se considera una distribución aceptable, propia de países europeos.

Días alta contaminación




La variable "Días alta contaminación" muestra una distribución sesgada a la izquierda, con un pico en los 5 días. La media es de 4 días, con una desviación estándar de 2 días. Esto sugiere que la mayoría de los pacientes experimentan entre 2 y 6 días de alta contaminación.





Las comunidades con mayor número de días de alta contaminación se corresponden con zonas del sur de España, que sugiere que, con el parámetro de medición de la contaminación del aire usado, los días que se supera una concentración mayor de 50 microgramos por metro cúbico de partículas PM10, se dan típicamente en zonas con aire procedente de África, como es el caso de Canarias y Murcia.


Horas trabajadas al mes y salario anual



Ambas siguen una distribución normal, con una media en 140 h/mes y 24000 €/año . El pico de 0 horas trabajadas y salario de 0€ se debe al número de menores de 16 años que no trabajan, que provoca una distorsión en la distribución.




Percepción de seguridad



Distribución uniforme, con una nota media de prácticamente 7, y una desviación estándar de 0.8, por lo que indica que la percepción de seguridad general de los datos es consistente, y se relaciona con una población que se siente segura en su entorno.


Nivel de felicidad



Vemos un valle en torno a los 6.8, lo que indica que la sensación de felicidad pasa de una nota "regular" a una nota "buena" a partir de los 7.5, aun siendo la media de 7.1, con una desviación estándar de 1.1. La tendencia es que la población se siente feliz, pero con una ligera insatisfacción.


Variables categóricas

Distribución de género




Son muy igualadas, con un valor aproximado de hombres y mujeres, con una ligera mayoría de mujeres (51.5%).

Distribución de actividad física



La mayoría de la población tiene un nivel bajo de actividad física. La población se considera sedentaria.


Distribución de asistencia a eventos



En todos los casos (cine, deporte, eventos culturales y directos), la mayoría de la población no asiste, siendo la razón otra que la falta de recursos (no_puede), por lo que se entiende que no hay mucho interés general en este tipo de actividades.




Distribución de estudios



La población se reparte mayoritariamente entre estudios secundarios y universitarios, con una muy baja tasa de analfabetismo. Si estudiamos conjuntamente la distribución de estudios con la de edades, vemos que la mayoría de la mayoría de la población en edad de estudiar, continúa sus estudios hasta la universidad, ya que se corresponden con los rangos de edades mayoritarias de la población.




Distribución de estado civil



La mayoría de la población se encuentra casada, o soltera, con una muy baja proporción de viudos y divorciados. Esto sugiere una población estable en cuanto a relaciones personales.


Distribución de satisfacción sanitaria



A todos los niveles (hospitales, dentistas, especialidades y medicina general), la población está satisfecha o muy satisfecha (en menor medida) en términos generales. Tanto las categorías de "insatisfecho" como "muy insatisfecho" son muy bajas, lo que indica una percepción equilibrada entre extremadamente positiva y extremadamente negativa, siendo la positiva la más predominante.



Distribución de la frecuencia de felicidad




La población ha sentido momentos de felicidad en el último mes muy a menudo, lo que indique que es generalmente feliz, o al menos siente momentos de felicidad con frecuencia.

La poca población que indica que nunca ha tenido un momento de felicidad en el último mes es muy baja, por lo que consideraremos en el análisis que tiene una clara tendencia positiva.

Correlación entre variables numéricas

Exceptuando algunas variables como días de alta contaminación, horas trabajadas al mes y salario anual, la mayoría de las variables numéricas no presentan una correlación significativa entre sí.



Vemos que los días de alta contaminación sí tiene una ligera correlación negativa con el nivel de felicidad, lo que sugiere que, a un mayor número de días de alta contaminación, menor es la percepción de felicidad de la población, aunque esta relación sea baja. Podemos decir que se aprecia la relación, pero no es un factor decisivo para en el grado de felicidad.

Las horas trabajadas al mes y el salario anual son las variables con mayor relación entre ellas, como es de esperar, ya que a mayor número de horas trabajadas al mes se presupone un mayor salario anual. Ambas tienen una ligera correlación positiva con la edad, lo que sugiere que a medida que la población envejece, trabaja más horas al mes y/o tiene un mayor salario anual.

